

Previsão de Preços de Imóveis

Disciplina: Machine Learning

Participantes:

- Gabriele Martinez - 1991045
- Julia Capellini - 1994186
- Lucas Gimenez - 1996567

Objetivo:

Prever o preço de venda de imóveis residenciais baseado em suas características.



Contexto do Problema:



A precificação de imóveis é crucial no mercado imobiliário. O preço depende de múltiplos fatores como tamanho, qualidade, localização e amenities.

Etapa 1 - Análise Exploratória

Nesta etapa inicial, o foco foi entender o comportamento do dataset e a relação das variáveis com o preço do imóvel. As principais observações foram:

- **Distribuição do preço:** Ao plotar o histograma da variável alvo (SalePrice), verificou-se uma assimetria positiva (Skewness de 1.88). Isso indica que a maioria das casas possui preços mais baixos, mas uma pequena quantidade de casas muito caras estica a “cauda” do gráfico para a direita.
- **Identificação de Outliers:** O gráfico de dispersão cruzando a Área Construída (GrLivArea) com o Preço revelou a presença de outliers. Notou-se a existência de casas com área superior a 4.000 sq ft, porém com preços desproporcionalmente baixos.
- **Qualidade e Correlações:** O boxplot de Qualidade Geral (OverallQual) vs. Preço evidenciou que imóveis de melhor qualidade são mais caros. Além disso, um heatmap revelou as variáveis numéricas com correlação mais forte com o preço, destacando-se a Qualidade Geral (0.79), Área Construída (0.71), Capacidade da Garagem (0.64) e Área da Garagem (0.62).





Etapa 2 - Pré Processamento

Para preparar os dados e evitar o vazamento de informações (Data Leakage), foram aplicadas as seguintes transformações



- **Limpeza e Engenharia de Atributos:** Foram removidos os outliers identificados na etapa anterior (Área > 4.000 e Preço < 300.000) e criou-se uma nova variável chamada TotalSF (somando as áreas de porão e andares).
- **Transformação da Variável Alvo:** Devido à assimetria do preço, aplicou-se uma transformação logarítmica ($\log_{10}$) para aproximar os dados de uma distribuição normal.
- **Divisão dos Dados:** A base foi dividida na proporção 60/20/20, resultando em 874 registros para Treino, 292 para Validação e 292 para Teste.
- **Pipelines de Transformação:** Utilizou-se a estrutura de Pipeline e ColumnTransformer para tratar valores nulos e escalonar os dados. Variáveis numéricas receberam preenchimento pela mediana e padronização (Z-Score). Variáveis ordinais e nominais tiveram nulos preenchidos pela moda e receberam, respectivamente, OrdinalEncoder e OneHotEncoder. As transformações foram ajustadas (fit) apenas no treino.

Etapa 3 - Comparação de Modelos

Foram implementados e avaliados três modelos: Linear Regression, Ridge e Random Forest.

- **Validação Cruzada:** No teste de K-Fold (K=5) sobre os dados de treino, observou-se um R^2 médio de 0.8614 para a Regressão Linear, 0.8617 para o Ridge e 0.8289 para o Random Forest.
- **Métricas na Base de Validação:** Após treinar os modelos e reverter o logaritmo das previsões para obter o preço real, as métricas finais obtidas foram:

- **Linear Regression:** MAE de 18.345,91 | RMSE de 24.650,77 | R^2 de 0.9159 | MAPE de 11,37%
- **Ridge:** MAE de 18.429,30 | RMSE de 24.728,38 | R^2 de 0.9153 | MAPE de 11,44%
- **Random Forest:** MAE de 20.286,07 | RMSE de 31.956,68 | R^2 de 0.8586 | MAPE de 12,15%



Etapa 4 - Análise Comparativa, Tuning e Avaliação Final

Com os modelos avaliados na base de validação, esta etapa aprofunda a análise comparativa, realiza o tuning de hiperparâmetros do melhor modelo e executa a avaliação definitiva no conjunto de teste, mantido isolado desde o início do projeto.

Justificativa do melhor modelo

O modelo de Regressão Linear se provou o mais adequado na base de validação, com R^2 de 0.9159 (91,59%), MAE de 18.345,91 e MAPE de 11,37%, os melhores resultados entre os três modelos avaliados. Apesar disso, para a versão final do projeto optou-se por refinar

o Random Forest via GridSearchCV, pois modelos baseados em árvores tendem a generalizar melhor em dados com não-linearidades e são menos sensíveis a heterocedasticidade, limitação observada nos resíduos da Regressão Linear.

Tuning de Hiperparâmetros (GridSearchCV)

Aplicou-se o GridSearchCV ao Random Forest combinando K-Fold (k=5) com o seguinte grid:

- `n_estimators`: [100, 200] — número de árvores na floresta.
- `max_depth`: [None, 10, 20] — profundidade máxima de cada árvore.
- `min_samples_split`: [2, 5] — mínimo de amostras para dividir um nó.

O GridSearchCV testou todas as combinações possíveis, selecionando os hiperparâmetros que maximizaram o R^2 médio na validação cruzada. O modelo otimizado foi então re-avaliado na base de validação para confirmar a melhoria antes da avaliação final.

Análise de Resíduos – Há Padrões Sistemáticos?

Observando o Gráfico de Resíduos da Regressão Linear, os erros se distribuem majoritariamente ao redor da linha de erro zero. Contudo, existe um padrão sistemático sutil: à medida que o preço predito aumenta, a dispersão dos resíduos também cresce, caracterizando heterocedasticidade. A amplitude do erro é nitidamente mais aberta para imóveis de maior valor.

Feature Importance – Quais Características Mais Afetam o Preço?

A análise de importância das variáveis, baseada nos coeficientes da Regressão Linear, confirmou que atributos ligados à dimensão e ao acabamento ditam os valores: `OverallQual` e `TotalSF` figuram no topo das características de maior impacto positivo no preço. Entre as variáveis nominais, bairros como `StoneBr` e `Veenker` apresentam coeficientes positivos elevados, enquanto `IDOTRR`, `BrDale` e `MeadowV` estão associados a coeficientes negativos, indicando redução no preço estimado.

Avaliação Final no Conjunto de Teste

O Random Forest otimizado pelo GridSearchCV foi avaliado no conjunto de teste, mantido completamente isolado durante todo o treinamento e ajuste. Este é o resultado mais honesto do modelo, pois ele nunca teve contato com esses dados anteriormente. Os resultados no teste foram consistentes com os obtidos na validação, indicando que o modelo generaliza bem para dados não vistos e não apresenta overfitting. O comportamento dos resíduos e a distribuição dos erros por faixa de preço foram verificados graficamente, confirmando as conclusões da análise comparativa.

Discussão – Em Que Faixa o Modelo Erra Mais?

Analisando o gráfico de Valores Reais vs. Preditos, o modelo é altamente preciso para imóveis de valor baixo e intermediário (até cerca de \$300.000), onde os pontos seguem de perto a linha diagonal de acerto perfeito. O modelo erra significativamente mais na faixa de

imóveis de alto valor (\$300.000–\$500.000 e acima), onde os pontos se distanciam da linha de acerto e surgem os maiores resíduos absolutos.

O boxplot de resíduos por faixa de preço confirma essa observação: a dispersão cresce progressivamente nas faixas mais altas. Esse comportamento é esperado, pois imóveis de luxo são sub-representados no dataset de treino e possuem características muito mais variadas, tornando a predição inerentemente mais difícil.